

# 오염된 태양광 데이터 정화 챌린지

Clean / Dusty 판별 — 데이터 정제로 성능을 끌어올리다

## Track A

Dusty 확률 예측 (ROC-AUC)

## Track B

오염 3종 탐지 (mean AP)

1,366 → 1,168

정제 후 학습 데이터

진행 타임라인: EDA·특징 설계 → 오염 점수화(Track B) → 정제 실험 E0~E5 → 최종 제출 → 발표 준비

발표 준비 : 김관호 / 김혜원

# 과제와 데이터 — 무엇을 풀어야 하는가

## Track A · Shine

- 태양광 패널 사진 → **Dusty(먼지)일 확률 예측**
- 평가: ROC-AUC (임계값 없이 분별력 측정)
- 제출: test 468장 × dusty\_prob

## Track B · Spot

- train 1,366장 각각의 오염 의심 점수 3종 예측
- 근접중복 · 라벨오류 · off-topic
- 평가: 세 축 **Average Precision**의 평균



## 데이터 구성

- train 1,366장 = Clean 813 + Dusty 553 (불균형 1.5:1)
- test 468장 (라벨 비공개) · 두 트랙의 train은 동일 파일

# 이 데이터셋의 네 가지 함정

1

## 근접 중복

같은 사진이 크기·밝기·자르기만 바뀌어 반복 → 학습 편향  
+ 평가 누수(leakage)

2

## 라벨 오류

Clean/Dusty 기준이 작업자마다 달라 라벨이 뒤집힘  
→ 틀린 정답지로 학습

3

## Off-topic




카탈로그 그래픽·인버터·풍경 등 패널 아닌 이미지 혼입  
→ 학습 잡음

4

## 촬영 편차

휴대폰·드론, 다른 각도·조명 → 정상적 다양성 (제거 대상 아님, 모델이 흡수)

# 탐색적 분석 — 세 가지 관찰



## 관찰 1

라벨 불균형은 완만(1.5:1) → ROC-AUC에 안정적, 리샘플링 불필요

## 관찰 2


해상도가 512px 상한에 몰림 → 일괄 리사이즈 흔적, 원본 다양성 소실

## 관찰 3

밝기 분포가 라벨 간 대부분 겹침 → '어두우면 Dusty' 같은 단순 규칙 불가, 질감·색 특징 필요



# 전체 파이프라인 — 정제가 모델보다 먼저다



## 설계 원칙

- ① 같은 신호를 다각도로 교차검증(해시+특징+기하)
- ② 오염별로 '제거 vs 식별' 구분
- ③ 모든 판단은 검증 성능으로 확인

# 특징 설계 — Dusty의 물리적 신호를 수치로

| 특징군          | 구성                                 | 왜 Dusty 판별에 유효한가        |
|--------------|------------------------------------|-------------------------|
| 색 (Color)    | HS 2D 히스토그램, Lab 통계, 채도 분포         | 먼지막 = 갈색·회색 색조 변화       |
| 질감 (Texture) | LBP 2스케일, HOG, 그리드 국소 대비 64칸       | 먼지 = 표면 미세 질감 변화, 대비 저하 |
| 선명도·주파수      | Laplacian 분산, FFT 8밴드, 그라디언트 히스토그램 | 헤이즈 = 고주파 에너지 감소        |
| 먼지 특화(추가)    | 다크채널(헤이즈), 스펙큘러 하이라이트, 컬러풀니스       | 깨끗한 유리 = 강한 반사 하이라이트    |
| 그래픽 신호       | 고유색 비율, 순백 배경, 텍스트 성분 수, 테두리 균일성   | 카탈로그·렌더링 이미지 탐지용        |

제약: 폐쇄 환경 → 사전학습 모델 사용 불가 → 도메인 지식 기반 수작업 특징 1,187차원

# 근접 중복 — 세 증거의 교차검증

근접 중복(Near-Duplicate) 탐지 예시 — 상하가 한 쌍



## 탐지 방법

- pHash-dHash 16x16 해밍거리 (크기·밝기 변형에 강함)
- PCA 특징 코사인 유사도 (색·구도 유사성)
- ORB 키포인트 기하 매칭 (자르기·회전 검증)
- 세 신호 가중 결합 = dup\_score

128쌍

강한 증거로 연결

117개

중복 그룹

243장

그룹 소속 이미지(17.8%)

# Off-topic — 패널이 아닌 것들을 찾아라

Off-topic(주제 이탈) 의심 상위 8장

train\_00659 ood=1.00



train\_01162 ood=1.00



train\_00750 ood=1.00



train\_00762 ood=1.00



train\_00887 ood=1.00



train\_00896 ood=1.00



train\_00516 ood=1.00



train\_00324 ood=0.99



## 탐지 방법 (v2)


- 그래픽 신호: 텍스트 성분 수, 테두리 균일성, 순백 배경 비율
- LOF: 특징 공간의 국소 밀도 이상치
- kNN 거리: 전체 분포에서의 고립도
- 가중 결합 = ood\_score

## 개선 반복

v1(LOF 중심)은 '어두운 진짜 패널'을 오탐 → 상위 예시를 눈으로 확인 후 텍스트·테두리·순백 신호를 추가한 v2로 교체.  
카탈로그·워터마크·설비 사진이 상위로 올라옴

# 라벨 오류 — 모델의 이의 제기

라벨 오류(Label Error) 의심 상위 8장 — 라벨과 모델 판단이 정반대



## 탐지 방법


- 5-fold OOF 예측 (자기 라벨을 보지 않은 모델의 판단)
- 라벨과 예측의 불일치 확률 = 의심 점수 (Confident Learning 사상)
- 2라운드: 의심 상위 제외 후 재학습 → 안정화
- off-topic과 중복 판정 방지: ood 상위는 감식

## 예시 해석

위 8장은 라벨이 Dusty지만 모델의 P(Dusty)가 0.1~0.3 — 육안으로도 깨끗한 패널. '살짝 뿌연' 경계 사례에서 작업자 기준이 갈린 흔적

# 오염 신호의 분포 — 꼬리를 노린다

오염 신호의 원시 분포 — 소수의 꼬리가 오염 후보



**submission\_trackB.csv — 1,366행 × (mislabel · dup · ood)**

제출 점수는 순위 정규화(0~1) — AP는 순위 기반 지표이므로 절대값보다 순서가 중요. 위 분포의 '꼬리'가 오염 후보군

## 점수 활용

Track B 점수가 그대로 Track A 정제 기준이 됨 → 두 트랙이 하나의 파이프라인

# 누수를 막는 평가가 먼저다


## 왜 그룹 교차검증인가

- 중복 이미지가 학습/검증 양쪽에 걸치면 점수가 부풀려짐 (누수)
- **일반 CV: 0.689 vs 그룹 CV: 0.663**
- 2.6pt의 착시 — 이 상태로 개선하면 방향을 잘못 잡는다
- 중복 그룹(연결요소)을 분할 단위로 →  
StratifiedGroupKFold 5-fold × 2 seeds

## 실험 사다리 (누적 적용)

- E0** 원본 + 일반 CV — 누수 착시 확인
- E1** 그룹 CV — 정직한 기준선
- E2** + off-topic 상위 8% 제거 (110장)
- E3** + 라벨오류 상위 7% 제거 (88장)
- E4** + 3모델 앙상블 (HistGB·LR·SVM)
- E5** + 먼지 특화 특징 406차원 추가

# 정제 단계별 성능 — 데이터가 모델을 이긴다



## +11.3pt


정직한 기준선(E1) 대비 최종  
(E5) 개선폭

- 라벨오류 제거가 최대 기여 (+7.4pt)
- 모델 교체·양상블 기여 (+2.5pt)
- 특징 보강 (+0.2pt)

**결론:** 같은 모델이라도 '무엇으로 배우고 어떻게 평가하느냐'가 성능의 대부분을 결정했다



# 특징 공간에서 본 데이터



## 읽는 법

- 좌: Clean/Dusty가 넓게 섞임 → 단순 문제가 아님
- 우: ood 상위(밝음)가 분포 가장자리에 위치 → 고립도 신호가 유효

정제 후 남은 1,168장이 학습의 재료 — 특징 공간의 '심장부'를 지키고 가장자리 잡음을 걷어냈다

# 최종 제출물과 정제 요약

| 구분         | 파일                           | 내용                                             |
|------------|------------------------------|------------------------------------------------|
| Track A    | submission_trackA.csv        | test 468장 dusty_prob — 정제 데이터 + 5모델 평균 (E5 구성) |
| Track A 보조 | submission_trackA_alt_GB.csv | HistGB 단독 — 앙상블 효과 리더보드 비교용                    |
| Track B    | submission_trackB.csv        | train 1,366장 × 오염 의심 점수 3종                     |

1,366

원본 train

-110

off-topic 제거

-88

라벨오류 제거

117그룹

중복 → CV 단위

1,168

최종 학습 데이터

## 결론 — 배운 것과 남은 것

### 배운 것

- 정제 > 모델: 최대 성능 기여는 라벨오류 제거 (+7.4pt)였다
- 평가 설계가 우선: 누수를 막지 않으면 개선의 방향 자체가 틀어진다
- 눈으로 검수: OOD v1 → v2 개선은 정량지표가 아니라 시각 검수에서 나왔다
- 오염 유형별 처방 분리: 중복=그룹화, OOD=제거, 라벨오류=보수적 제거

### 남은 것 (다음 단계)

- 사전학습 임베딩(CLIP 등) 도입 시 전 단계 상향 기대 — 본 환경 제약으로 미적용
- 의심 상위 라벨의 인간 재검수 — 제거 대신 복원으로 데이터 회수
- 반복 정제 루프: 더 좋아진 모델로 오염 점수 재산출 → 재정제
- 운영 관점: 신규 수집 데이터에 동일 파이프라인 적용해 '들어올 때 거른다'

# 데이터를 씻으니, 모델이 보이기 시작했다

정제 파이프라인은 재사용 가능한 자산입니다 — 다음 수집 배치에도 같은 기준이 적용됩니다.

감사합니다 · Q&A